

Bezczujnikowe śledzenie sondy USG na potrzeby rekonstrukcji 3D

Problem i Cel

Problem: Obrazowanie 2D to tylko płaskie "plastry" anatomii. Pełny obraz 3D wymaga **drogich i nieporęcznych czujników zewnętrznych**, co ogranicza dostępność tej technologii.

Cel: Opracowanie algorytmu do **precyzyjnego śledzenia ruchu 3D głowicy USG**, eliminując potrzebę stosowania dodatkowego, kosztownego sprzętu.

SOTA

Metody Klasyczne (do 2017): Oparte na prostej korelacji plamek (Speckle Decorrelation).

- *Wada:* Niska dokładność przy szybkim ruchu i rotacji sondy.

Wczesne Deep Learning (2018-2020): Wykorzystanie CNN (np. Prevost et al.) do regresji ruchu.

- *Wada:* Błędy kumulują się w czasie (Drift), brak analizy sekwencji.

Nowoczesne Podejścia (2023-2025): Architektury hybrydowe CNN + LSTM/Transformers.

- **MoGLo-Net (2025):** Wykorzystuje mechanizm uwagi (Attention) i pamięć czasową (LSTM) do redukcji dryftu.

Wynik: Obecny standard (SOTA) osiąga błąd dryftu na poziomie ~13%.

Podejście na tle State of the Art


Analiza literatury wskazuje, że **największym wyzwaniem jest ruch w osi Z (Out-of-Plane)**.

Dlatego proponujemy **Podejście Hybrydowe**:

- **Oś X/Y**: Używamy **Visual Odometry** (Optical Flow), ponieważ jest to metoda stabilna i geometrycznie poprawna dla ruchu w płaszczyźnie.
- **Oś Z**: Adaptujemy architekturę **ResNet + LSTM** (inspirowaną MoGLO-Net), ponieważ Deep Learning najlepiej radzi sobie z nieliniową dekorelacją plamek.

Cel: Osiągnięcie kompromisu między szybkością klasycznych algorytmów a dokładnością sieci neuronowych.

In-Plane Tracking (X/Y) – Visual Odometry



Technologia:

- **Algorytm:** Lucas-Kanade Optical Flow.
- **Filtracja:** RANSAC + estimateAffinePartial2D.
- **Funkcja:** Śledzenie punktów charakterystycznych i obliczanie macierzy transformacji całego obrazu (przesunięcie + rotacja).

Wyniki:

- Wykryto i skorygowano rotację układu współrzędnych.
- **Dokładność (MAE):** ~0.7 mm dla ruchu w płaszczyźnie.

Out-of-Plane Estimation (Z) – Deep Learning

Architektura: Zmodyfikowany ResNet-18.

Input:

- Para sąsiednich klatek (t , $t+1$) sklejona w tensor 2-kanałowy.
- Sieć uczy się bezpośrednio z mapy cech tekstury (Speckle Decorrelation).

Output:

- Estymacja dystansu ΔZ (w milimetrach).

Trening:

- Dane: Zbiór TUS-REC (z walidacją na Subject 050).
- Loss Function: MSE (Mean Squared Error).


Wyniki – Rekonstrukcja Trajektorii Z

Opis wykresu:

- **Zielona linia:** Prawdziwa trajektoria.
- **Czerwona linia:** Predykcja sieci neuronowej.
- **Obserwacje:** Model poprawnie rozpoznaje kształt ruchu, przyspieszenia i zwolnienia ręki lekarza.

Metryki:

- **MAE (Średni błąd):** 4.90 mm.
- **Final Drift:** 15.73 mm (na dystansie ~140 mm).



Wyniki – Pełna Rekonstrukcja 3D





Figure 5



Opis:

- Połączenie Visual Odometry (X/Y) i ResNet (Z).
- Wizualizacja pokazuje odtworzoną ścieżkę sondy w przestrzeni 3D.

Kluczowy wynik:

- **FDR (Final Drift Rate): 15.6%.**
- Jest to wynik porównywalny z aktualnym stanem wiedzy (State-of-the-Art). Np. model MoGLo-Net (2025) osiąga FDR na poziomie ~12%.

Wnioski i Dalsze Kroki

Osiągnięcia:

1. Zbudowano działający pipeline "Trackerless US".
2. Potwierdzono, że sieć neuronowa (ResNet) potrafi "widzieć" głębokość poprzez dekorelację plamek.
3. Osiągnięto dryft na poziomie 15%, co jest obiecującym wynikiem dla metody bezczujnikowej.

Next Steps:

1. Skalowanie Treningu: Wykorzystanie pełnego zbioru danych TUS-REC w celu poprawy generalizacji modelu.
2. Implementacja **LSTM**:
 - *Inspiracja*: Analiza najnowszej literatury, w tym artykułu "**MoGLo-Net**" (2025).
 - *Dlaczego*: Autorzy tej pracy wykazali, że dodanie modułu LSTM do analizy sekwencji klatek pozwala zredukować **Final Drift Rate (FDR) do poziomu 12.05%**.
 - *Cel*: Zastosowanie tej samej architektury (CNN+LSTM), aby wygładzić trajektorię i zmniejszyć błąd do poziomu ~12%.